

**Important notice :**

L'examen consistera en une **présentation de 20 minutes** (sur une de ces questions).

*The exam consists of a **20-minute presentation** over one of these questions.*

Les questions ci-dessous sont un guide pour discuter chaque chapitre. Le but de la discussion est de s'assurer de la compréhension du contexte général et des détails des techniques, et de leurs interconnexions.

*The questions below are a guide to start addressing each related chapter. The discussion will make sure of the understanding of both the general context and the details of the techniques, and their inter-connections.*

---

**Question 1: (Modeles / Models)**

Décrivez la structure du modèle Vectoriel pour la RI en partant des documents bruts, jusqu'à la réponse à une requête. Décrivez les faiblesses du modèle creux.

*Describe the structure of the Vector IR model, from the raw documents, until being able to answer a query. Discuss weaknesses of this sparse model.*

**Question 2: (Modeles / Models)**

Décrivez la structure du modèle Probabiliste (BIR) pour la RI en partant des documents bruts, jusqu'à la réponse à une requête. Décrivez les faiblesses du modèle creux.

*Describe the structure of the probabilistic Binary Independence Retrieval model, from the raw documents, until being able to answer a query. Discuss weaknesses of this sparse model.*

**Question 3: (Modeles / Models)**

Décrivez la structure du modèle des représentations neuronales (Word Embeddings) en partant des documents bruts, jusqu'à la réponse à une requête. Précisez les différences entre les modèles denses et les modèles creux. Expliquez le modèle Word2Vec et comment il introduit des non-linéarités entre les termes.

*Describe the structure of the Word Embedding model, from the raw documents, until being able to answer a query. What are the differences between sparse and dense word embedding vectors? Explain the word2vec architecture and how it introduces non-linear relationships between the terms.*

**Question 4: (Evaluation / Evaluation)**

Présentez défis et les composants d'un processus d'évaluation d'un système de Recherche d'Information en détaillant le calcul de mesures de performances et les intuitions sous-jacentes.

*Present the challenges and components of a evaluation process for an Information Retrieval system. Give details and a full example for the computation of performance measures and their underlying intuition.*

**Question 5: (ISL / LSI)**

Présentez la motivation et la structure du modèle d'Indexation par Sémantique Latente. Expliquez notamment ce qu'est un Concept et comment répondre à une requête en utilisant ce modèle.

*Describe the motivation and structure of the Latent Semantic Indexing model. In particular explain what a "concept" is in this context and how to answer a query using this model.*

**Question 6: (RI Web / Web IR)**

Expliquez la motivation pour l'analyse de la structure du Web (comme système d'information) dans la Recherche d'Information. Détaillez (principe et algorithme) au moins un modèle effectuant une telle analyse (PageRank, HITS).

*Present the motivation for analysing the structure of the Web (as Information System) in the context of Information Retrieval. Detail (principle and algorithm) at least one model performing such an analysis (e.g, PageRank, HITS).*

**Question 7: (Indexation texte / Text IR)**

Discutez les différents composants d'un système de RI textuelle et leurs détails: vous pourrez discuter les défis et méthodes de la création du vocabulaire avec la prise en compte des statistiques associées, le modèle de recherche ainsi que l'indexation sous-jacente. Décrivez les lois de Zipf et de Heap

*Present the various components of a Text IR system and their details: you may address the challenges and methods related to the creation of the vocabulary, taking into account associated statistics, the search model and the indexing strategy. Describe the Zipf's and Heap's law.*

**Question 8: (Indexation / Indexing)**

Décrivez le principe de la méthode d'exclusion géométrique pour l'indexation. Décrivez son application aux distances Euclidiennes pour l'indexation par pivot. Discutez la différence entre les méthodes d'indexation pour les représentations creuses (type TF-IDF) et dense (type Word2Vec).

*Describe the generic principle of geometric exclusion for indexing. How does the Euclidean exclusion rule apply in pivot-based indexing?*

*Describe indexing techniques related to sparse embedding (eg TF-IDF) and dense embedding (eg Word2Vec).*

**Question 9: (Filtrage collaboratif / recommendation systems)**

Présentez la problématique et les solutions au problème de recommandation. On pourra présenter les données collectées et leur modélisation, les méthodes de traitement et de prédiction de jugement.

Pourquoi est-ce que les modèles latent (bas rang) sont pertinents dans ce contexte ? Dans le contexte de jugements sur des films, décrivez le lien entre la matrice user-jugement et les matrices factorisées par SVD.

*Present the challenges and methods for recommendation systems. You may present the structure of the data and its models, processing and predictions strategies. Why are latent factor models useful in this context? Suppose you want to build a recommendation system to predict movie ratings using SVD. How does the user-movie rating matrix relate to the factor matrices obtained from SVD?*

**Question 10: (Recherche de cible / Target search)**

Détaillez la problématique et solution pour la recherche de cible dans une collection. Vous pourrez discuter le modèle d'interaction spécifique, le principe du compromis exploration/exploitation et le modèle de prédiction dans la recherche de cible.

*Present the challenges and methods for performing target search over collection. The discussion may include the specific interaction model, the exploration/exploitation tradeoff, and the prediction model in the target search process.*

---

*Of course the scope of the exam is the full set of lectures so questions are simply a starter for the discussion, that may cover more than the topic, since many links can (and should) be created.*